

Analítica de Recursos Humanos: Determinantes Salariales y Modelación de Compensaciones

Análisis de determinantes salariales para director de recursos humanos, TalentCo.

Karen Rojas

Alejandra González

Martina Manriquez

Contexto y objetivos del proyecto

El proyecto consiste en analizar la estructura salarial de TalentCo, una empresa con empleados de distintas regiones, niveles de cargo y departamentos. El problema surge porque el área de recursos humanos sospecha que los salarios no se estarían asignando de manera consistente, ya que podrían presentarse diferencias según variables como educación, género, región, experiencia.

El objetivo del análisis fue utilizar herramientas de analítica de datos para identificar los factores que realmente están influyendo en el salario de los trabajadores de TalentCo. Para ello, se trabajó con un dataset de compensaciones, realizando una exploración y limpieza de los datos, luego visualizaciones, pruebas de hipótesis y modelos de regresión lineal para lograr explicar e incluso predecir los salarios.

De esta manera, el proyecto busca entregar evidencia cuantitativa que sirva para comprender mejor la estructura de pago de TalentCo y apoyar las decisiones de Recursos Humanos orientadas a una asignación salarial más consistente y basada en datos.

Descripción del conjunto de datos

Para el análisis se usó el archivo `employee_compensation.csv`. Este dataset contiene la información de aproximadamente 10.000 empleados de TalentCo.

La variable principal del análisis es el salario, correspondiente al salario bruto anual de cada empleado. La base incluye variables numéricas como años de experiencia, edad, puntaje de desempeño, que permiten analizar la relación entre estas y el salario. Además, se consideran variables categóricas como nivel educacional, departamento, nivel de trabajo, región y género. Permitiendo estudiar posibles diferencias de salario cuando estas características varían.

En conjunto, estas variables permiten desarrollar un análisis integral de la estructura salarial de TalentCo, sirviendo como base para la exploración de datos, las pruebas de hipótesis y los modelos de regresión aplicados posteriormente.

Análisis exploratorio de datos

La primera parte del estudio corresponde al análisis exploratorio de los datos (EDA). El objetivo de esta etapa fue conocer la estructura del dataset antes de comenzar a trabajar con él, ya sea realizar modelos predictivos, pruebas estadísticas, entre otros. Para ello se utilizó la librería Pandas proveniente de Python, especializada en el manejo y análisis de estructuras de datos.

En primer lugar, se cargó el archivo `employeecompensation.csv`, utilizando la función `readcsv()`, quedando así los datos almacenados en un dataframe llamado `dfsalary`, todo esto para poder trabajar con sus filas y columnas.

Luego se utilizó `df_salary.head(10)` para mostrar las primeras 10 filas de data frame. Permitiendo revisar la estructura de los datos, comprobar que el dataframe estuviera siendo leído y también para observar algunos ejemplos y así entender su forma. En esta visualización se pudieron observar las variables, y algunos valores NaN, lo que anticipó la necesidad de revisar los valores nulos.

A continuación, se aplicó el comando `df_salary.dtypes` para observar el tipo de dato de cada columna, y distinguir las variables numéricas, reconocidas como `float64` y categóricas, identificadas como `object`.

Valores nulos

Luego, se revisó la existencia de valores faltantes. Gracias a la utilización de `df_salary.index` se identificó que el dataframe posee 10.100 registros. Posteriormente se aplicó `df_salary.isnull().sum()` para contar la cantidad de valores nulos que había en cada columna. Los resultados mostraron que existía en promedio 360 valores nulos por columna, presentes en la mayoría de las columnas, excepto en `job_level`, que no presentaba ningún valor faltante. Las variables que más nulos presentó fue `performance_score` con 603 casos, `education_level` con 506 y `gender` con 501 casos.

Para observar la magnitud de estos valores con respecto del total de datos, se calculó el porcentaje de valores faltantes por columna, observándose así que los porcentajes de datos faltantes eran bajos. Con un máximo de 5,97% para la variable `performance_score`. Este paso permite reconocer que la base de datos requería de un tratamiento antes de comenzar a trabajar con ella de manera profunda.

Para tratar con los valores faltantes, se creó una copia de dataframe original, esto para conservar la base inicial y poder realizar los cambios sobre una nueva versión de los mismos datos. Para las variables numéricas se reemplazaron los valores faltantes por la mediana de cada columna, esto porque es menos sensible a valores extremos o atípicos que el promedio. En el caso de las variables categóricas los valores fueron reemplazados por la moda, es decir, el valor más frecuente de cada columna.

Finalmente se volvió a ejecutar `df_salary_imputed.isnull().sum()` para verificar el proceso realizado, obteniendo resultados correctos, ya que se mostraban cero valores nulos en cada columna.

Valores duplicados

Al terminar con el trabajo de eliminación de valores nulos, se observó la existencia de datos duplicados en la base de datos. Para esto se utilizó

`df_salary_imputed.duplicated().sum()` que identifica las filas repetidas, mostrando la existencia de 97 registros duplicados.

Para evitar que los mismos valores influyeran más de una vez en los análisis, se eliminaron mediante `drop_duplicates()`. El nuevo dataframe se volvió a ejecutar con el comando que cuenta los duplicados para comprobar esta eliminación y el resultado fue de 0 registros, confirmando que ya no existían valores duplicados.

Estandarización y consistencia de datos

Posteriormente se creó el dataframe definitivo, llamado `df_salary_final`. En esta etapa se aplicaron filtros de consistencia sobre las variables numéricas, por ejemplo, se mantuvieron valores donde años de experiencia fueran mayor o igual a cero, la edad estuviera dentro de rangos válidos, el puntaje de desempeño dentro de 1 y 5, y los años de experiencia no fueran superiores a la edad del empleado. Permitiendo eliminar incoherencias y valores inválidos para el análisis.

Después se realizó una estandarización de las variables categóricas. Todo esto por el motivo de que, al haber palabras con una escritura diferente, por ejemplo, Finance y FINANCE fueran tomadas como datos completamente diferentes. Es por esto que con `.str.upper()` se convirtieron todos los valores a mayúsculas, y con `.str.strip()` se eliminaron los espacios en blanco que existieran al inicio o al final de cada string. Además de reemplazar valores escritos como NAN, por un real valor nulo que python pudiera identificar, y nuevamente ser reemplazadas por la moda de cada variable.

Finalmente se imprimieron los valores de cada columna categórica para verificar la limpieza, los resultados mostraron categorías consistentes: departamentos como SALES, HR, FINANCE, MARKETING y ENGINEERING; regiones como EAST, WEST, SOUTH y NORTH; niveles de cargo JUNIOR, MID y SENIOR; género MALE y FEMALE; y niveles de educación BACHELOR, MASTER y PHD.

En conclusión, esta fase permitió obtener una base más limpia, sin duplicados ni nulos y con valores coherentes y uniformes. Logrando así reducir los errores al momento de comparar variables, visualizarlas y en modelos estadísticos posteriores.

Cálculo de estadísticas descriptivas para variables numéricas

Luego de limpiar y estandarizar la base de datos, se utilizó el `df_salary_final` para calcular estadísticas descriptivas. Primero se seleccionaron sólo las variables numéricas: salario, años de experiencia, edad y nivel de desempeño.

Se utilizó el método `.describe()` para obtener las principales medidas descriptivas, conformado por cantidad de registros, media, desviación estándar, mínimo, máximo y cuartiles. Además, se calculó la asimetría gracias a `.skew()` y la curtosis mediante

.kurtosis(), para analizar la distribución de cada variable e identificar si los datos presentan valores extremos importantes o si están sesgados.

Los resultados muestran que, tras la limpieza, el dataframe quedó con 9915 observaciones válidas. Para la variable principal de este estudio, salary, el promedio fue de 95.683 USD anuales, con una mediana de 91.701 USD. Esta diferencia, junto con una asimetría positiva y una curtosis alta muestran que la distribución del salario está sesgada hacia la derecha, es decir, existen algunos salarios muy elevados que “inflan” el promedio.

En el caso de los años de experiencia, se observó que la mayor parte de los empleados tiene niveles de experiencia bajos o medios. En la variable edad, se observó una distribución concentrada en trabajadores jóvenes, ya que la mediana fue de 29 y el promedio de 29,35 años. Finalmente, para el nivel de desempeño se presentó una mediana de 3,0 y una media de 3,01, lo que sugiere que el desempeño está muy cercano al punto medio de la escala que lo mide.

Además, se calcularon el Coeficiente de Variación (CV) y el Coeficiente de Variación Robusto (RCV) para comparar la dispersión relativa entre variables. El CV se calculó dividiendo la desviación estándar por la media. En cambio, el RCV dividiendo el rango intercuartílico (IQR) por la mediana.

Los resultados indican que Years_Experience es la variable que presenta la mayor dispersión relativa, registrando un CV de 75,85% y un RCV de 116,67%. Respecto a salary, se obtuvo un CV de 31,79% y un RCV de 37,29%, evidenciando diferencias importantes en los niveles salariales dentro de la organización. Estos indicadores resultan útiles para las etapas posteriores del análisis, ya que ayudan a entender cómo se distribuyen las variables antes de realizar visualizaciones o modelos de regresión.

Cálculo de estadísticas descriptivas para variables categóricas

Además de las variables numéricas, también se realizó un cálculo de estadísticas de las variables cualitativas. Al ser categóricas, no se resumen mediante promedio, desviaciones o mínimos y máximos, sino mediante frecuencias y moda.

Para realizarlo, se calculó la moda para cada columna con .mode()[0], es decir el valor que aparece con mayor frecuencia en el dataframe. Posteriormente se usó .value_counts() para conseguir el número de observaciones por categoría, y luego el porcentaje que representa cada categoría sobre el total. Además de calcular la cantidad de categorías únicas gracias a .nunique().

El análisis de la Variación Modal (VMo) permite concluir que la muestra es altamente heterogénea en términos geográficos y organizacionales. Las variables region (≈72%), department (≈68%) y job level (≈60%) superan ampliamente el umbral del 50%, lo que demuestra que las observaciones están muy dispersas y que las modas no logran

representar al grueso del grupo (por ejemplo, en region el 72% de los datos se reparte fuera de la categoría principal). En contraste, educational level ($\approx 49\%$) y gender ($\approx 48\%$) muestran valores bajo el cincuenta por ciento, reflejando una estructura más equilibrada y con una concentración moderada en sus categorías principales.

Elaboración de visualizaciones

La primera visualización fue un boxplot para analizar la distribución del salario según el cargo del empleado. Para esto se importaron las librerías seaborn y matplotlib, usadas para la construcción de gráficos.

El gráfico se generó mediante la función `sns.boxplot()`, definiendo como eje x la variable `job_level` y como eje y la variable `salary`. Además, se usó `order=[JUNIOR, MID, SENIOR]` para mostrar los cargos en orden jerárquico. Se realizó una personalización de tamaño, colores, y apariencia general.

Este gráfico permitió visualizar que los empleados junior presentan los salarios más bajos, seguidos por mid y en último lugar los empleados senior registran los salarios más altos, mostrando una relación positiva entre el nivel jerárquico del cargo y el salario que reciben. También se identificaron valores atípicos por encima y por debajo de los valores habituales, lo que sugiere que, aunque el nivel de cargo influye de gran manera en las remuneraciones, otras variables también contribuyen a la explicación de las diferencias salariales.

El segundo gráfico es un diagrama de dispersión para analizar la relación entre los años de experiencia y el salario. Se utilizó `sns.scatterplot()`, con años de experiencia como eje x y salario como variable del eje y.

Este gráfico permite observar visualmente si existe una tendencia entre ambas variables. En general, se aprecia una relación positiva: a medida que aumentan los años de experiencia, los salarios tienden a ser mayores. Esto es coherente con la lógica laboral, ya que empleados con mayor trayectoria suelen acceder a mejores remuneraciones.

No obstante, también se observa una dispersión importante de los datos. Para un mismo nivel de experiencia existen empleados con salarios bastante distintos, e incluso aparecen valores extremos tanto en salarios bajos como altos. Esto indica que la experiencia por sí sola no explica completamente el salario.

Luego del análisis específico entre experiencia y salario se construyeron diagramas de dispersión para comparar el salario con las otras variables numéricas del dataset: años experiencia, edad y puntaje de desempeño.

Mediante `plt.subplots()` se obtuvo una figura con tres gráficos ordenados hacia abajo. Mediante un ciclo for se designaba la variable `salary` en el eje Y, y la variable

correspondiente según el gráfico en el eje X. Además de ajustar los detalles de personalización para una mejor visualización y entendimiento del gráfico.

El primer gráfico, salary vs years_experience, muestra una tendencia positiva entre ambas variables. En general, los empleados con más años de experiencia tienden a presentar salarios más altos. Sin embargo, la dispersión de los puntos indica que existen diferencias salariales importantes incluso entre trabajadores con un mismo nivel de experiencia.

El segundo gráfico, salary vs age, también evidencia una relación positiva moderada. A medida que aumenta la edad, los salarios tienden a ubicarse en rangos más altos, aunque nuevamente se observa variabilidad. Esto puede explicarse porque la edad suele estar relacionada con la trayectoria laboral, pero no determina por sí sola el salario.

El tercer gráfico, salary vs performance_score, no muestra una tendencia clara. Los puntos se distribuyen de manera relativamente similar a lo largo de toda la escala de desempeño, lo que sugiere que el puntaje de desempeño reciente no parece tener una relación lineal fuerte con el salario.

Para complementar los gráficos de dispersión, se elaboró un mapa de calor de correlaciones entre las variables numéricas del dataset. Primero se seleccionaron solo las columnas cuantitativas mediante `select_dtypes(include=['number'])` y luego se calculó la matriz de correlación con `.corr()`. Finalmente, esta matriz se visualizó con `sns.heatmap()`, mostrando los valores de correlación dentro de cada celda.

El resultado muestra que salary tiene una correlación positiva moderada con years_experience (0,61) y con age (0,56) lo que indica que los salarios tienden a ser mayores a medida que la experiencia y la edad también van aumentando. En cambio, performance_score presenta una muy baja correlación con salary (0,09). Esto sugiere que el desempeño de los trabajadores no parece explicar las diferencias salariales, esto podría interpretarse como una señal de que el rendimiento no está relacionado con las remuneraciones, siendo quizás un punto que logre reducir los incentivos a mejoras en el desempeño.

Se construyeron histogramas para analizar la distribución de las variables numéricas de df_salary_final. Para esto, primero se seleccionaron las columnas cuantitativas con `select_dtypes(include=['number'])` y luego se usó `sns.histplot()`, lo que permitió la realización un gráfico para cada variable.

El histograma de salary muestra una concentración en salarios medios y una cola hacia la derecha, indicando la presencia de algunos salarios altos. years_experience se concentra principalmente en niveles bajos y medios de experiencia, mientras que age

muestra una mayor cantidad de empleados entre los 20 y 35 años. Por último, `performance_score` se distribuye entre 1 y 5, con mayor concentración alrededor de 3.

Como ultima visualización, se construyeron gráficos de barra para las variables categóricas. Para esto se utilizó `sns.countplot()` para generar dicho gráfico para cada variable.

El objetivo de estos gráficos fue observar la distribución según las características cualitativas. Se aprecia que el nivel educacional más frecuente es BACHELOR, el departamento con mayor presencia es ENGINEERING, que la región SOUTH tiene levemente más registros. El nivel de cargo más común es MID. En cuanto al género, hay una distribución equilibrada, con una leve diferencia a favor de las mujeres.

Descripción de prueba de Hipótesis

Las pruebas de hipótesis estadísticas nos permiten tomar decisiones basadas en evidencia cuantitativa a partir de muestra de datos. En el contexto de análisis de recursos humanos, son fundamentales para responder preguntas acerca de equidad, estructura y determinación de la compensación.

Se ejecutaron dos pruebas de hipótesis sobre el dataset de compensaciones de TalentCo, orientadas por la siguiente pregunta de negocio planteada: ¿Los años de experiencia determinan de manera significativa las diferencias salariales de los empleados de TalentCo? ¿Existe además una diferencia salarial estadísticamente significativa entre empleados Junior y Senior?

Para responder estas preguntas se aplicaron dos métodos complementarios; la correlación de Pearson (para la relación entre la experiencia y salario) y la prueba t para dos muestras independientes (para comparar los salarios de empleados Junior vs Seniors). Ambas pruebas se ejecutaron con un nivel de significancia del 5%.

Primera prueba – Correlación de Pearson

La primera prueba evalúa si existe una relación lineal positiva estadísticamente significativa entre los años de experiencia (*Years_experience*) y el salario bruto anual (*Salary*). Se utiliza el coeficiente de correlación de Pearson (*r_coef*), cuyo valor poblacional se denota ρ (*p-valor de la prueba*).

La hipótesis será:

Hipótesis	Descripción	
H0	$\rho = 0$	Años de exp. No tienen que ver con salario
H1	$\rho > 0$	Años están positivamente asociados con salario.

El código que se implemento es el siguiente:

```
import scipy.stats as stats

r_coef, p_val_linear = stats.pearsonr(

    df_salary_final["Years_Experience"], df_salary_final["Salary"]

)

print(f"Coeficiente de correlación de Pearson (r): {r_coef:.4f}")

print(f"p-valor de la prueba: {p_val_linear}")
```

Y gracias a este se obtuvieron los siguientes resultados; Coeficiente de Pearson (*r_coef*) = 0,6097 y *p-valor* (*p_val_linear*) < 0,01 (con resultado de significancia al 5%), por lo tanto, se rechaza la hipótesis *H0* ya que, según la evidencia estadística, los años de experiencia tienen una relación lineal positiva con el salario bruto anual. El coeficiente *r* indica una correlación positiva moderada a fuerte, a mayor experiencia (uno de los determinantes salariales más relevantes), mayor es el salario promedio. Por otro lado, el valor nulo de *p* nos indica que la correlación no es al azar.

Segunda prueba – Prueba t

La segunda hipótesis contiene una pregunta de alto interés para TalentCo; ¿Existe una diferencia salarial estadísticamente significativa entre los empleados de nivel Junior y los de nivel Senior?; esta pregunta es clave para validar si los niveles de cargo se reflejan en los salarios.

Se utilizo la prueba t de Welch (*equal_var=False*) para más exactitud ya que esta no asume igualdad entre varianzas, y es más recomendada para análisis de finanzas.

La hipótesis se definió:

Hipótesis	Formulación	
H0	$\mu_{junior} = \mu_{senior}$	Salario prom. Junior IGUAL al de senior.
H1	$\mu_{junior} \neq \mu_{senior}$	Salario prom. junior es DIFERENTE al de senior.

El código implementado para esta hipótesis fue el siguiente:

```
salarios_junior = df_salary_final[df_salary_final["Job_Level"] == "JUNIOR"][

    "Salary"

]
```

```
salarios_senior = df_salary_final[df_salary_final["Job_Level"] == "SENIOR"][  
    "Salary"  
]
```

2. Ejecutamos la prueba t de dos muestras independientes

equal_var=False aplica la corrección de Welch (es la práctica más segura en finanzas/RH)

```
t_stat, p_val_bonus = stats.ttest_ind(  
    salarios_junior, salarios_senior, equal_var=False  
)  
  
print(f"t estadístico: {t_stat:.4f}")  
  
print(f"p-valor de la prueba: {p_val_bonus}")
```

Y los resultados obtenidos de este fueron; t_estadístico= -81,2799 y p-valor de la prueba=0,0, por lo que la hipótesis nula se rechaza, debido a que el salario promedio de los empleados Senior es significativamente mayor que el de los Junior.

Regresión lineal con variables categóricas

En esta fase se construyó un modelo de regresión lineal para explicar el salario anual de los trabajadores a partir de variables categóricas y numéricas. Anterior a la modelación, se justificó brevemente que variables podrían ser influyentes en el salario. Se esperaba que años de experiencia laboral, el nivel educacional y el cargo fueran relevantes, ya que representan la experiencia acumulada del empleado, el nivel de formación que obtuvo y la posición jerárquica dentro de la organización.

También se decidió mantener variables como género, edad y región, aunque eventualmente pudieran no ser significativas, porque tienen importancia desde una perspectiva de negocio. Por ejemplo, el género permite evaluar posibles brechas salariales, la región ayuda a identificar diferencias por ubicación geográfica y la edad permite analizar si existe alguna relación entre etapa laboral y remuneración.

Luego se preparan los datos para ser utilizados en un modelo numérico. Se creó una copia de la base llamada df_modelo_salary. Se codificó la variable job_level para representar la jerarquía del cargo. Siendo su orden natural: junior, mid y finalmente

senior. Para las variables categóricas se aplicó one-hot encoding mediante `pd.get_dummies()`. Para transformar dichas variables en variables binarias de 0 o 1.

Después de codificar las variables, se definieron las variables explicativas (X) y la variable objetivo (Y), correspondiente al salario (`salary`). Luego, se dividieron los datos en un conjunto de entrenamiento y otro de prueba usando `train_test_split()`. Se utilizó el 80% de los datos para entrenar el modelo y el 20% para evaluarlo. Esto dejó 7.932 empleados en entrenamiento y 1.983 empleados en prueba.

Finalmente se logró la construcción de dos modelos de regresión lineal. El primero se estimó con `statsmodels`, usando `sm.OLS()`. Este permitió conseguir una tabla detallada con errores estándar, coeficientes y p-valores. El segundo modelo se entrenó con `scikit-learn`, lo que permitió realizar predicciones y calcular métricas de desempeño.

Uno de los resultados más relevantes corresponde a `job_level`, cuyo coeficiente positivo indica que avanzar en la jerarquía del cargo tiene un efecto importante sobre el salario. Esto es coherente con lo observado previamente en el análisis exploratorio, donde los trabajadores Senior presentaban salarios superiores a los Mid y Junior. Del mismo modo, los niveles educacionales Master y PhD también presentan efectos positivos en comparación con la categoría base, lo que indica que una mayor formación académica se relaciona con mayores remuneraciones.

Con el modelo de `scikit-learn` se generaron predicciones sobre los datos de entrenamiento. Para evaluar el desempeño se calcularon distintas métricas: MAE, MAPE, RMSE, entre otras. Estas permiten analizar el error promedio del modelo y su capacidad para explicar las variaciones del salario.

En el conjunto de entrenamiento, el modelo obtuvo un MAE de 7.091,51, lo que significa que, en promedio, las predicciones del salario se desvían aproximadamente 7.091 USD respecto del valor real. El MAPE fue de 12,90%, indicando un error porcentual promedio moderado. Por otro lado, el RMSE fue de 20.652,37, métrica que penaliza con mayor fuerza los errores grandes, por lo que refleja la presencia de algunas predicciones más alejadas del valor real.

Respecto al poder explicativo, el modelo obtuvo un R^2 de 0,53 y un R^2 ajustado de 0,52 en entrenamiento, lo que indica que lograr explicar el 53% de la variabilidad de los salarios a partir de las variables incluidas en el estudio. Aunque su capacidad es moderada, existen otros factores no considerados en el dataframe que podrían afectar directamente en las remuneraciones. La regresión lineal permitió identificar y cuantificar el efecto de variables relevantes como la experiencia, el nivel de cargo y la educación sobre el salario. De igual manera, la incorporación de variables como género, región y departamento aporta información útil para analizar posibles diferencias internas y evaluar la equidad de las compensaciones dentro de TalentCo.

Análisis y refinamiento del modelo

En esta etapa se realizó un análisis más detallado de modelo de regresión con la finalidad de evaluar la calidad de sus variables y revisar posibles problemas estadísticos que pudieran afectar la interpretación de los resultados. Para esto se analizó la significancia de los coeficientes, la multicolinealidad y el comportamiento de los residuos.

Primero, se revisaron los p-valores obtenidos en el modelo OLS. Estos permiten evaluar si cada variable aporta información relevante para explicar las remuneraciones. En general, el modelo mostró que la mayoría de las variables incluidas resultaron significativas, ya que presentaron p-valores menores a 0,05. Esto indica que variables como experiencia, edad, desempeño, nivel de cargo, educación, departamento, región y género tienen algún grado de relación con el salario cuando se controlan las demás variables del modelo.

Luego, se analizó la multicolinealidad con el cálculo del Factor de Inflación de la varianza (VIF). Esto permite determinar si una variable explicativa está muy correlacionada con otras variables del modelo. Un VIF alto puede generar problemas porque aumenta la inestabilidad de los coeficientes y dificulta interpretar el efecto individual de cada predictor.

Los resultados mostraron que algunas variables presentan VIF elevados, especialmente `job_level`, `years_experience` y `age`. Esto era esperable, ya que estas variables están relacionadas entre sí: a mayor edad suele existir mayor experiencia laboral, y a mayor experiencia también puede aumentar la probabilidad de ocupar un cargo más alto. Sin embargo, se decidió mantener estas variables, ya que tienen una justificación importante desde el punto de vista del negocio y permiten representar dimensiones distintas del salario: trayectoria, etapa laboral y jerarquía organizacional.

Posteriormente, se estudiaron los residuos del modelo, es decir, la diferencia entre los salarios reales y los predichos. Para ello, se construyó un histograma de residuos con una curva de densidad, junto con estadísticas descriptivas como media, desviación estándar, mínimo, máximo, asimetría y curtosis. El resultado mostró que la media de los residuos es cercana a cero, lo cual es positivo, porque indica que el modelo no tiende a sobreestimar o subestimar sistemáticamente los salarios. Sin embargo, también se observa una dispersión importante y presencia de valores extremos. Además, se aplicó una prueba de normalidad sobre los residuos. El resultado confirmó que los residuos no siguen una distribución normal. Esto se explica por la existencia de salarios atípicos y por la asimetría de los salarios.

En conclusión, el análisis de refinamiento permitió identificar que el modelo tiene una capacidad explicativa moderada y que la mayoría de sus variables son relevantes para explicar el salario. No obstante, también se detectaron posibles problemas de multicolinealidad y residuos no completamente normales. Por esta razón, el modelo debe entenderse como una aproximación útil para detectar patrones salariales, pero no como una explicación definitiva de todas las diferencias de compensación dentro de TalentCo.

Informe de Negocio

informe de gestión interna: estructura salarial talentco

Para: Director de Recursos Humanos

De: Departamento de Analítica y Estrategia

Este documento explica de forma clara cómo se determinan los sueldos en TalentCo, tras analizar los datos reales de 7,932 colaboradores. El objetivo es identificar qué habilidades premia la empresa, dónde se concentra el presupuesto y qué distorsiones debemos corregir para garantizar una política de pagos justa y transparente.

El estudio demuestra que el nivel de estudios avanzados genera el mayor impacto económico. Un profesional con Doctorado (PhD) percibe, en promedio, 16,230 USD más al año en comparación con un trabajador con título básico, mientras que un Magíster aporta un extra de 7,264 USD anuales. Asimismo, la evolución de la carrera interna y la experiencia práctica son fundamentales: cada ascenso jerárquico (como pasar de nivel Mid a Senior) representa un aumento de 15,810 USD anuales. Además, la empresa premia el conocimiento práctico sobre la antigüedad; cada año de experiencia añade 1,280 USD a la renta anual, mientras que un año más de edad solo aporta 258 USD.

Al contrastar las áreas, se evidencia una penalización drástica en los equipos de soporte frente a Tecnología e Ingeniería, la rama mejor remunerada. Recursos Humanos presenta la mayor brecha negativa con -18,380 USD al año por el mismo nivel de cargo, seguida de cerca por Ventas con -16,430 USD y Marketing con -13,230 USD. Esto indica un sesgo de compensación agresivo hacia los roles técnicos. Paralelamente, existe una clara disparidad geográfica: trabajar en la región North genera un premio de +2,623 USD, mientras que pertenecer a South implica un descuento de -2,151 USD, lo que exige evaluar si responde al costo de vida o a una descentralización ineficiente de roles clave.

El hallazgo más crítico es la existencia de una brecha salarial por motivos de género sin justificación técnica. A igual experiencia, cargo, estudios, región y desempeño, el colaborador hombre percibe en promedio 1,361 USD más al año que su par mujer. Este

problema institucional urgente afecta el clima laboral y expone a la empresa a riesgos legales.

Como acción inmediata, proponemos un “Plan de igualdad salarial” para nivelar la diferencia de 1,361 USD en puestos equivalentes. Segundo, las reglas para ser promovido deben ser públicas, medibles y evaluadas por comités técnicos para eliminar la discrecionalidad en los ascensos. Finalmente, se debe revisar la competitividad en RRHH y ventas para evitar la fuga de talentos, evaluando mejorar sus sueldos base o diseñar un sistema de comisiones más agresivo en el área comercial.